

IA 26

Guide, Module 19

LM Studio

Faire tourner l'IA en local, sans connexion et en toute confidentialité

*L'IA souveraine : le modèle sur votre machine,
vos données qui ne sortent jamais.*

Matthieu Jardin, Marketing AI
Édition 2026

Vous pouvez obtenir une copie du livre en format .pdf en cliquant-ici

Sommaire

Préface : Pourquoi ce guide ?

Introduction : Le défi de l'IA souveraine

Partie 1 : Contexte et enjeux : et si l'IA tournait sur votre machine ?

Partie 2 : Les concepts fondamentaux

Partie 3 : La méthode pas à pas : mettre en place son IA locale

Partie 4 : Cas pratiques

Partie 5 : Outils, templates et checklists

Les 7 pièges à éviter

Synthèse et plan d'action en 7 jours

Pour aller plus loin

À propos de la FORMATION IA 26

Préface : Pourquoi ce guide ?

Depuis le Module 1, une réalité accompagne tous les outils que vous avez découverts : quand vous écrivez à une IA, votre texte part vers les serveurs d'un fournisseur. C'est le fonctionnement normal du cloud et, pour la plupart des usages, c'est parfaitement acceptable. Mais pas pour tous. Certaines données ne devraient jamais quitter votre machine. Certains contextes secteurs sensibles, déplacements sans connexion, exigences de souveraineté appellent une autre approche. C'est exactement ce que propose LM Studio : faire tourner le modèle d'IA sur votre propre ordinateur.

Ce guide est le dix-neuvième d'une série de 26 guides qui accompagnent le programme FORMATION IA 26. Il ouvre le bloc « IA locale, privée et assistants connectés ». Le basculement qu'il décrit est radical : avec LM Studio, l'IA ne vit plus dans un centre de données distant, mais sur votre poste. Pas de connexion requise, pas de données qui partent ailleurs, pas de limite d'usage, pas de dépendance à un fournisseur. En contrepartie, des compromis à comprendre la puissance, le matériel, la mise en place. Ce module vous donne les deux faces de la médaille.

Vous y trouverez : ce qu'est LM Studio et le principe de l'IA locale ; les modèles ouverts Llama, Mistral, Qwen, Phi, Gemma, Mixtral ; la quantisation, qui rend l'IA locale possible sur une machine normale ; le matériel nécessaire ; le réglage des paramètres, du simple à l'expert ; le serveur local ; et un plan d'action concret pour mettre en place votre propre IA souveraine. L'objectif est unique : que vous refermiez ce guide capable de faire tourner une IA sur votre machine et de savoir précisément quand c'est le bon choix.

« L'IA dans le cloud, c'est commode. L'IA en local, c'est souverain. La maîtrise, c'est de savoir, pour chaque donnée, lequel des deux s'impose. » Principe directeur du Module 19

Introduction : Le défi de l'IA souveraine

Le frein, ici, est double et c'est ce double frein qu'il faut nommer. Le premier est une fausse évidence : « le cloud marche très bien, pourquoi se compliquer la vie ? ». Elle ignore qu'il existe des cas où le cloud n'est tout simplement pas une option acceptable. Le second est une fausse difficulté : « faire tourner une IA sur son ordinateur, c'est trop technique ». C'était vrai il y a quelques années ; ce ne l'est plus, justement grâce à des outils comme LM Studio. Entre la fausse évidence et la fausse difficulté, il y a une compétence concrète à acquérir : savoir mettre en place une IA locale, et savoir quand y recourir.

Ce Module 19, et donc ce guide, traite explicitement de l'IA qui tourne sur votre machine. Trois questions structurantes guident l'intégralité des pages qui suivent :

1. Qu'est-ce que l'IA locale, et qu'est-ce que LM Studio change concrètement par rapport au cloud ?
2. Comment mettre en place une IA locale modèles, quantisation, matériel, paramètres ?
3. Quand l'IA locale est-elle le bon choix, et quand le cloud reste-t-il préférable ?

Ces trois questions correspondent à trois corpus : la nature de l'IA locale (LM Studio, le modèle sur votre poste), sa mise en place (modèles ouverts, quantisation, matériel, réglages), et le choix raisonné (local ou cloud, selon le besoin). Chaque corpus est traité dans la suite du guide avec ses concepts-clés, ses applications concrètes et ses pièges typiques.

Partie 1 : Contexte et enjeux : et si l'IA tournait sur votre machine ?

1.1 Le basculement : de l'IA dans le cloud à l'IA sur votre poste

Tous les outils des dix-huit premiers modules ont un point commun : ils fonctionnent dans le cloud. Le modèle d'IA tourne sur les serveurs d'un fournisseur ; votre ordinateur ne fait qu'envoyer votre demande et recevoir la réponse. Ce modèle a d'immenses avantages la puissance, la simplicité, l'accès aux meilleurs modèles et il restera, pour la majorité des usages, la bonne solution.

L'IA locale propose un basculement complet : le modèle est téléchargé sur votre machine, et c'est votre ordinateur qui fait le travail. Conséquence directe et fondamentale : votre demande ne part nulle part. Pas de transmission, pas de serveur tiers, pas de connexion nécessaire une fois le modèle installé. Ce n'est pas « une variante » du cloud c'est une autre architecture, avec une autre logique. Et cette autre logique répond à des besoins que le cloud, par construction, ne peut pas satisfaire : la confidentialité absolue, l'indépendance, le fonctionnement hors ligne.

1.2 Les douleurs typiques de la dépendance au cloud

Avant de progresser, il faut nommer ce qui freine. Voici les difficultés les plus fréquentes de la dépendance exclusive à l'IA dans le cloud :

- **La donnée qui doit rester chez soi.** Un document, une information dont la sensibilité interdit qu'il quitte la machine et qu'on s'interdit donc de traiter avec l'IA.
- **L'absence de connexion.** Un déplacement, un lieu sans réseau fiable et l'IA devient inaccessible.
- **La dépendance au fournisseur.** Un changement de tarif, de conditions, de disponibilité du service et l'usage est suspendu à une décision externe.
- **Les limites d'usage subies.** Des quotas, des plafonds qui bornent l'usage selon la formule souscrite.
- **Le coût récurrent.** Un abonnement qui court, indépendamment de l'intensité réelle de l'usage.
- **La fausse difficulté du local.** Croire que l'alternative l'IA sur son poste est réservée aux techniciens.

« Le cloud n'a pas de défaut : il a un périmètre. L'erreur n'est pas de l'utiliser c'est de croire qu'il est la seule option. » *Principe directeur du Module 19*

1.3 Le pari de ce guide

Le pari de ce guide, et plus largement du programme FORMATION IA 26, est que l'IA locale est aujourd'hui à la portée de tout professionnel et qu'elle constitue le complément indispensable du cloud, pas son remplaçant. LM Studio rend la mise en place accessible ; ce guide fournit la méthode pour la réussir et la grille pour savoir quand l'employer. Aucune compétence de développeur n'est requise : seulement la compréhension de quelques concepts et un peu de méthode. Les parties suivantes le détaillent.

À RETENIR

L'IA locale n'est pas « le cloud en moins bien » ni « le cloud en plus compliqué ». C'est une architecture différente, qui répond à des besoins différents : la confidentialité absolue, le fonctionnement hors ligne, l'indépendance. Le bon utilisateur de 2026 ne choisit pas le local contre le cloud il dispose des deux, et sait, pour chaque donnée et chaque contexte, lequel s'impose.

Partie 2 : Les concepts fondamentaux

Cette partie présente les dix notions qui permettent de comprendre et d'exploiter LM Studio. Aucune ne demande de compétence de développeur. Une fois ces notions assimilées, vous saurez mettre en place et piloter une IA locale.

2.1 LM Studio : qu'est-ce que c'est

LM Studio est une application de bureau qui permet de télécharger, charger et utiliser des modèles d'IA directement sur votre ordinateur. Là où ChatGPT ou Gemini sont des services en ligne, LM Studio est un logiciel que vous installez et qui fait tourner le modèle localement. Son interface ressemble à celle d'un assistant conversationnel classique : on dialogue avec le modèle. La différence est invisible à l'écran mais fondamentale : tout se passe sur votre machine.

2.2 L'IA locale : le modèle qui tourne sur votre ordinateur

C'est le concept central. Un modèle d'IA est, fondamentalement, un très gros fichier de paramètres. Dans le cloud, ce fichier réside sur les serveurs du fournisseur. En local, vous téléchargez ce fichier sur votre machine, et c'est le processeur et idéalement la carte graphique de votre ordinateur qui exécute les calculs. Conséquences : aucune donnée ne sort, aucune connexion n'est nécessaire après le téléchargement, aucun tiers ne voit ce que vous faites. L'IA locale, c'est l'IA dont vous êtes physiquement propriétaire.

2.3 Les modèles ouverts : Llama, Mistral, Qwen, Phi, Gemma, Mixtral

L'IA locale repose sur les modèles ouverts : des modèles dont les concepteurs mettent les paramètres à disposition, ce qui permet de les télécharger et de les exécuter soi-même. Llama (Meta), Mistral, Qwen (Alibaba), Phi (Microsoft), Gemma (Google), Mixtral comptent parmi les familles les plus connues. Chacune se décline en plusieurs tailles. Comme pour les gammes du Module 4, le bon réflexe n'est pas d'apprendre une liste, mais de comprendre la logique : un modèle plus gros est plus capable mais plus exigeant ; un modèle plus petit est plus léger mais plus limité.

2.4 La quantisation : ce qui rend l'IA locale possible

Voici le concept qui change tout, et qu'il faut bien saisir. Un modèle, à pleine précision, est un fichier énorme trop lourd pour la mémoire d'un ordinateur ordinaire. La quantisation est une technique de compression : elle réduit la précision des paramètres du modèle pour en diminuer fortement la taille et les besoins en mémoire. Un modèle quantisé tient sur une machine normale et tourne plus vite. La contrepartie est une légère perte de qualité souvent imperceptible pour l'usage courant. Concrètement : c'est la quantisation qui fait passer l'IA locale du « réservé aux serveurs » au « possible sur votre portable ».

2.5 Le matériel : ce qu'il faut pour faire tourner un modèle

L'IA locale a un coût, mais il est matériel, pas récurrent. Trois éléments comptent. La mémoire vive (RAM) : c'est elle qui détermine quelle taille de modèle vous pouvez charger. La carte graphique (GPU) : si votre machine en a une, elle accélère considérablement les calculs ; sinon, le processeur s'en charge, plus lentement. L'espace de stockage : les modèles sont des fichiers volumineux. Le principe à retenir : on ne choisit pas un modèle « dans l'absolu », on choisit un modèle que sa machine peut faire tourner c'est le matériel qui fixe le plafond.

2.6 Charger, tester et comparer les modèles

LM Studio facilite trois gestes essentiels. Charger : télécharger un modèle depuis l'application, puis le mettre en mémoire pour l'utiliser. Tester : dialoguer avec lui pour évaluer sa qualité sur vos besoins réels. Comparer : essayer plusieurs modèles sur les mêmes demandes pour identifier celui qui convient le mieux à votre usage et à votre machine. Cette boucle charger-tester-comparer est le cœur de la pratique : avec l'IA locale, vous n'êtes plus l'utilisateur d'un modèle imposé vous êtes celui qui choisit son modèle.

2.7 Les paramètres essentiels : température, longueur, contexte

LM Studio donne accès aux paramètres qui gouvernent la génération ceux-là mêmes qui restaient cachés dans les outils cloud. Trois sont essentiels. La température : elle règle le degré d'aléa des réponses, comme vu au Module 2 basse pour la constance, haute pour la créativité. La longueur de réponse : la taille maximale de ce que le modèle produit. La fenêtre de contexte : la quantité de texte que le modèle peut prendre en compte en une fois. Régler ces trois paramètres, c'est adapter le comportement du modèle à votre usage un contrôle que le cloud ne vous laisse généralement pas.

2.8 Le niveau expert : sampling, presets, ressources

Pour qui veut aller plus loin, LM Studio ouvre un réglage fin. L'échantillonnage (sampling) avec des paramètres comme Top-K, Top-P, Min-P ou la pénalité de répétition affine la façon dont le modèle choisit ses mots. Les presets permettent d'enregistrer des configurations de réglages réutilisables. La gestion des ressources répartition entre processeur et carte graphique, nombre de fils d'exécution optimise la vitesse. Ces réglages experts ne sont pas indispensables pour démarrer : ils sont la marge de progression de l'utilisateur avancé. L'important est de savoir qu'ils existent, et que l'IA locale offre un degré de contrôle inégalé.

2.9 Le serveur local : ouvrir le modèle à vos autres outils

LM Studio ne se limite pas au dialogue dans son interface : il peut aussi fonctionner comme un serveur local. Concrètement, le modèle qui tourne sur votre machine devient accessible à d'autres applications de votre ordinateur, comme s'il était un service mais un service entièrement local. C'est la porte d'entrée vers des usages plus avancés : connecter un modèle local à un autre outil, sans que rien ne passe par le cloud. Le Module 25, sur le Model Context Protocol, prolongera cette logique.

2.10 Forces, limites et bon usage de l'IA locale

L'honnêteté commande de poser les deux faces. Les forces de l'IA locale : la confidentialité absolue les données ne sortent pas ; l'indépendance pas de connexion, pas de fournisseur, pas de limite d'usage ; le coût matériel et ponctuel, pas récurrent ; le contrôle un réglage fin impossible dans le cloud. Les limites : les modèles locaux, surtout quantifiés, restent généralement moins puissants que les meilleurs modèles cloud ; ils dépendent de votre matériel ; et la mise en place demande un effort initial. Le bon usage en découle : l'IA locale pour les données sensibles, l'usage hors ligne et l'indépendance ; le cloud pour la puissance maximale et la simplicité. Les deux, et non l'un contre l'autre.

Partie 3 : La méthode pas à pas : mettre en place son IA locale

Cette partie traduit les concepts en séquence opérationnelle. Suivez-la dans l'ordre : chaque étape construit la suivante. L'ensemble se met en place en une semaine, à raison d'une heure par jour.

Étape 1 : Évaluer son matériel et installer LM Studio

Commencez par regarder votre machine : combien de mémoire vive, une carte graphique ou non, quel espace de stockage disponible ? Ce diagnostic détermine ce que vous pourrez faire. Installez ensuite LM Studio l'application est gratuite et disponible pour les principaux systèmes. Cette première étape, purement matérielle, conditionne tout le reste.

Étape 2 : Choisir et télécharger son premier modèle

Pour un premier modèle, ne visez pas le plus gros : visez un modèle adapté à votre machine, dans une famille connue. Mieux vaut un modèle modeste qui tourne bien qu'un modèle ambitieux qui sature votre mémoire. Téléchargez-le depuis LM Studio, qui vous guide dans le choix selon votre matériel.

Étape 3 : Comprendre la quantisation et choisir la bonne version

Un même modèle existe en plusieurs versions quantisées plus ou moins compressées. Une compression forte allège le modèle mais réduit un peu la qualité ; une compression légère préserve la qualité mais demande plus de mémoire. Le bon choix est un équilibre : la version la plus capable que votre machine peut faire tourner confortablement. Testez si besoin deux versions pour sentir la différence.

Étape 4 : Charger le modèle et dialoguer en local

Chargez le modèle en mémoire et dialoguez avec lui dans LM Studio. Posez-lui vos questions habituelles, confiez-lui des tâches réelles. Prenez la mesure de ce que vous tenez : une IA qui répond, alors que rien ne quitte votre ordinateur et qu'aucune connexion n'est active. C'est le moment où le concept devient une expérience concrète.

Étape 5 : Comparer plusieurs modèles sur ses besoins

Téléchargez un ou deux autres modèles et comparez-les sur vos demandes réelles : qualité des réponses, vitesse, confort d'usage sur votre machine. C'est le « duel de modèles » du Module 4, transposé au local. L'objectif : identifier le ou les modèles qui constitueront votre dotation d'IA locale.

Étape 6 : Régler les paramètres pour son usage

Ajustez les paramètres essentiels selon vos usages : température basse pour les tâches qui exigent de la constance, plus haute pour le brainstorming ; longueur de réponse et fenêtre de contexte selon vos besoins. Si vous le souhaitez, explorez les réglages experts. Enregistrez vos bonnes configurations en presets, pour les réutiliser.

Étape 7 : Définir quand utiliser l'IA locale plutôt que le cloud

Établissez votre règle de partage. En première approche : l'IA locale pour les données sensibles, les contextes hors ligne, et les usages où l'indépendance prime ; le cloud pour la puissance maximale et la simplicité. Notez cette règle elle est le vrai livrable du module, et elle s'enrichira avec les Modules 20 et 21.

MISE EN PRATIQUE Votre première IA souveraine

Choisissez une tâche que vous n'osiez pas confier à une IA cloud, parce que les données étaient trop sensibles. Étape 1 : installez LM Studio et un modèle adapté à votre machine. Étape 2 : coupez votre connexion internet. Étape 3 : réalisez la tâche avec votre IA locale. Vous venez de faire ce qui était impossible jusqu'ici : utiliser l'IA sur une donnée confidentielle, avec la certitude physique qu'elle n'est partie nulle part.

Partie 4 : Cas pratiques

Trois illustrations concrètes pour ancrer la méthode dans des situations réelles. Chaque cas part d'une situation initiale, pose un diagnostic, puis détaille l'application.

Cas 1 : Le professionnel qui manipule des données confidentielles

Situation : Claire exerce dans un secteur où le secret est la règle. Elle voit ses confrères gagner du temps avec l'IA, mais elle s'interdit d'y toucher : ses documents ne peuvent, en aucun cas, partir vers un serveur tiers.

Diagnostic : Claire a un vrai besoin d'IA, mais un interdit absolu de transmission. Tant qu'elle ne connaît que l'IA cloud, elle est condamnée à se priver de l'outil.

Application : Claire met en place LM Studio sur sa machine, avec un modèle adapté à son matériel. Elle peut désormais faire analyser, résumer, reformuler ses documents confidentiels en ayant la certitude physique que rien ne quitte son ordinateur. Pour ses tâches non sensibles, elle continue d'utiliser le cloud, plus puissant. Elle n'a pas remplacé une approche par l'autre : elle a, enfin, les deux et une règle claire pour savoir laquelle employer.

Cas 2 : La personne qui a besoin d'une IA hors ligne

Situation : Idriss travaille souvent en déplacement, dans des lieux où la connexion est instable ou absente. Au moment précis où il aurait besoin de l'IA, l'IA cloud n'est pas joignable.

Diagnostic : Idriss dépend d'une ressource la connexion qu'il ne maîtrise pas. Son outil le lâche exactement quand il en a besoin.

Application : Idriss installe une IA locale sur son ordinateur portable. Une fois le modèle téléchargé, plus aucune connexion n'est nécessaire : dans le train, dans un lieu isolé, en avion, son IA reste disponible. Il garde le cloud pour le bureau et les tâches lourdes, mais il a désormais une IA qui le suit partout y compris là où le réseau ne va pas. L'indépendance vis-à-vis de la connexion a changé sa façon de travailler en mobilité.

Cas 3 : L'équipe qui veut maîtriser ses coûts et sa dépendance

Situation : Une équipe utilise intensivement l'IA cloud. Les abonnements s'accumulent, les limites d'usage sont parfois atteintes, et la direction s'inquiète d'une dépendance croissante à des fournisseurs externes.

Diagnostic : L'équipe n'a qu'une corde à son arc. Tout son usage de l'IA y compris les tâches simples et répétitives passe par le cloud, avec son coût récurrent et sa dépendance.

Application : L'équipe adopte une approche mixte. Elle identifie les usages qui ne demandent pas la puissance maximale reformulations, résumés courts, traitements répétitifs et les bascule sur des modèles locaux via LM Studio. Elle réserve le cloud aux tâches qui l'exigent vraiment. Le coût récurrent baisse, les limites d'usage cessent d'être un frein, et la dépendance se réduit sans rien perdre en capacité, puisque le cloud reste là où il est irremplaçable.

Partie 5 : Outils, templates et checklists

Les concepts ne valent que par leur application. Cette partie regroupe les outils opérationnels que vous pouvez utiliser dès cette semaine.

5.1 Template : la grille de choix d'un modèle local

Les critères à croiser pour choisir un modèle adapté :

1. Matériel disponible : mémoire vive, carte graphique, espace de stockage.
2. Taille du modèle : compatible avec le matériel, sans saturer la mémoire.
3. Niveau de quantisation : l'équilibre entre légèreté et qualité préservée.
4. Usage visé : tâches courantes, multilingue, raisonnement, code...
5. Qualité réelle : testée sur vos demandes, pas supposée d'après le nom.
6. Confort d'usage : vitesse de réponse acceptable sur votre machine.

5.2 Template : réglages de paramètres selon l'usage

Des points de départ à ajuster, à enregistrer en presets :

Usage	Réglage de référence
Tâches factuelles, constance	Température basse, pour des réponses stables et reproductibles.
Brainstorming, créativité	Température plus haute, pour des réponses variées.
Réponses courtes	Longueur de réponse limitée, pour aller à l'essentiel.
Traitement de longs textes	Fenêtre de contexte large, si le matériel le permet.
Réglage fin	Sampling (Top-K, Top-P, Min-P) à explorer au niveau expert.

5.3 Checklist : avant d'installer son IA locale

- Ai-je évalué le matériel de ma machine : mémoire, carte graphique, stockage ?
- Ai-je identifié un usage réel qui justifie le local confidentialité, hors ligne, indépendance ?
- Le modèle visé est-il adapté à mon matériel, et non choisi « dans l'absolu » ?
- Ai-je compris le compromis de la quantisation : légèreté contre qualité ?
- Ai-je prévu de tester le modèle sur mes besoins avant de l'adopter ?

5.4 Checklist : IA locale ou IA cloud ? le bon réflexe

- La donnée est-elle sensible au point de ne jamais devoir quitter ma machine ? → IA locale.
- Vais-je travailler sans connexion fiable ? → IA locale.
- L'indépendance vis-à-vis d'un fournisseur ou des limites d'usage est-elle un enjeu ? → IA locale.
- Ai-je besoin de la puissance maximale et de la simplicité ? → IA cloud.
- Ai-je une règle de partage claire entre les deux et la respecte-je ?

5.5 Outils et ressources recommandés

- **LM Studio.** L'application du module : télécharger, charger et utiliser des modèles d'IA en local.
- **Les modèles ouverts (Llama, Mistral, Qwen, Phi, Gemma, Mixtral).** Les familles à découvrir et à tester selon votre matériel.
- **Le serveur local de LM Studio.** Pour ouvrir, plus tard, votre modèle local à d'autres outils en préparation du Module 25.
- **Votre grille de choix et vos presets.** Pour systématiser le choix de modèle et le réglage des paramètres.
- **La FORMATION IA 26.** Le fil conducteur : 26 modules et 12 mois de mises à jour pour suivre l'évolution des outils.

Les 7 pièges à éviter

Sept pièges classiques faussent l'adoption de l'IA locale. Les nommer permet de les éviter.

PIÈGE N°1 Croire que le cloud suffit toujours

Le cloud a un périmètre, pas une couverture totale. Certains besoins confidentialité, hors ligne appellent le local.

PIÈGE N°2 Croire le local réservé aux techniciens

C'était vrai hier. Des outils comme LM Studio rendent aujourd'hui l'IA locale accessible à tout professionnel.

PIÈGE N°3 Choisir un modèle trop gros pour sa machine

On ne choisit pas un modèle dans l'absolu : c'est le matériel qui fixe le plafond.

PIÈGE N°4 Ignorer la quantisation

C'est elle qui rend l'IA locale possible. Mal la comprendre, c'est choisir une version inadaptée.

PIÈGE N°5 Attendre du local la puissance du cloud

Les modèles locaux sont généralement moins puissants. Le local se choisit pour ses forces propres, pas pour égaler le cloud.

PIÈGE N°6 Opposer local et cloud

Ce ne sont pas des rivaux : ce sont deux architectures complémentaires, à employer chacune à sa place.

PIÈGE N°7 Installer sans règle d'usage

Une IA locale sans règle claire de partage avec le cloud reste un outil sous-exploité.

Synthèse et plan d'action en 7 jours

Synthèse : les 10 idées-clés

1. L'IA locale fait tourner le modèle sur votre machine : rien ne part vers un serveur tiers.
2. LM Studio rend cette mise en place accessible, sans compétence de développeur.
3. L'IA locale repose sur les modèles ouverts : Llama, Mistral, Qwen, Phi, Gemma, Mixtral.
4. La quantisation compresse les modèles : c'est elle qui rend le local possible sur une machine normale.
5. C'est le matériel mémoire, carte graphique qui fixe le plafond du modèle utilisable.
6. La pratique de base : charger, tester, comparer pour choisir son modèle.
7. L'IA locale donne accès aux paramètres température, contexte et à un réglage fin inégalé.
8. Le serveur local ouvre le modèle à vos autres outils, sans passer par le cloud.
9. Forces : confidentialité, indépendance, coût ponctuel, contrôle. Limites : puissance, matériel, mise en place.
10. Local et cloud ne s'opposent pas : on dispose des deux, avec une règle de partage claire.

Plan d'action en 7 jours

Les 10 idées-clés ne valent que mises en mouvement. Voici un plan opérationnel sur 7 jours une heure par jour suffit.

- **Jour 1 Lundi** : évaluez le matériel de votre machine et installez LM Studio.
- **Jour 2 Mardi** : choisissez et téléchargez un premier modèle adapté à votre matériel.
- **Jour 3 Mercredi** : comprenez la quantisation et sélectionnez la bonne version du modèle.
- **Jour 4 Jeudi** : chargez le modèle, coupez la connexion, et dialoguez en local.
- **Jour 5 Vendredi** : comparez deux ou trois modèles sur vos besoins réels.
- **Jour 6 Samedi** : réglez les paramètres selon vos usages et enregistrez vos presets.
- **Jour 7 Dimanche** : écrivez votre règle de partage entre IA locale et IA cloud.

À RETENIR

Le Module 19 ouvre le bloc « IA locale et privée ». Sa vraie valeur n'est pas de remplacer le cloud c'est de vous donner une seconde architecture, pour les cas où le cloud ne peut pas répondre. Le jour où vous traitez une donnée confidentielle avec une IA, connexion coupée, en sachant qu'elle n'est partie nulle part, vous avez franchi un cap : l'IA n'est plus seulement un service que vous consommez c'est aussi un outil que vous possédez.

Pour aller plus loin

Bibliographie commentée

- **LLMs in Enterprise (Ahmed Menshawy)**. Pour comprendre les enjeux du déploiement des modèles de langage en entreprise, dont le local.
- **Clawdbot OpenClaw The Local-First AI Agent Handbook**. Construire et héberger son propre assistant IA privé : la logique du local poussée plus loin.
- **Intelligence artificielle vulgarisée (Aurélien Vannieuwenhuyze)**. Le machine learning et le deep learning par la pratique, pour comprendre ce que contient un modèle.
- **AI Engineering Building Applications with Foundation Models (Chip Huyen)**. Pour approfondir ce qu'est un modèle et comment il s'exécute.
- **Le Guide de l'Intelligence Artificielle au travail (Franca Salis-Madinier)**. Pour les enjeux de données et de souveraineté, au cœur de l'IA locale.
- **Guide de l'IA Générative (Cyril de Sousa Cardoso, Fanny Parise)**. Pour resituer l'IA locale dans la logique générale de l'IA générative.
- **Comprendre l'IA en 15 minutes (Thomas Clermont)**. Un rappel des notions de base, utile avant d'aborder modèles et paramètres.

Liens avec les autres modules FORMATION IA 26

Le Module 19 ouvre le bloc « IA locale, privée et assistants connectés ». Les modules voisins le prolongent naturellement :

- **Module 1 L'IA, les LLM et ChatGPT** : la règle de confidentialité y trouve ici sa réponse la plus radicale.
- **Module 4 Modèles de langage** : la logique de lecture des gammes se transpose aux modèles ouverts.
- **Module 9 IA émergentes** : plusieurs de ces acteurs proposent des modèles ouverts exécutables en local.
- **Module 20 Msty et Ollama** : d'autres outils d'IA locale, à découvrir après LM Studio.
- **Module 25 Model Context Protocol** : le serveur local de LM Studio prépare la connexion d'un modèle local à vos outils.

À propos de la formation IA 26

Ce guide est une introduction au Module 19 d'une formation complète de 26 modules.

FORMATION IA 26 est une formation conçue par Matthieu Jardin, fondateur d'Impact Croissance et de Marketing AI. Elle s'adresse aux dirigeants, indépendants, solopreneurs et équipes qui veulent maîtriser l'intelligence artificielle pour gagner en productivité et développer leur activité.

Format

- 26 modules vidéo, un panorama complet de l'IA générative et de ses outils.
- Formation structurée module par module, accessible à votre rythme.
- Supports pédagogiques complets et bonus exclusifs par module.
- Accompagnement sur groupe WhatsApp privé et pod LinkedIn d'entraide.
- 12 mois de mises à jour des supports offertes.

Les 26 modules en un coup d'œil

- **Modules 1 à 4** : fondations et maîtrise de ChatGPT (IA-LLM, prompts, fonctions avancées, modèles).
- **Modules 5 à 9** : le panorama des IA génératives (Gemini, Claude, Copilot, Grok, Mistral, IA émergentes).
- **Modules 10 à 13** : productivité augmentée (NotebookLM, Noota, Gamma, Napkin, recherche avancée).
- **Modules 14 à 18** : agents IA et navigateurs intelligents (Genspark, Manus, Flowith, Skywork, Perplexity).
- **Modules 19 à 21** : IA locale, privée et assistants connectés (LM Studio, Msty, Ollama, Dust, H Company).
- **Modules 22 et 23** : création visuelle avec l'IA (images et vidéos).
- **Modules 24 et 25** : automatisation (Make, Zapier, n8n) et Model Context Protocol (MCP).
- **Module 26** : IA pour codeurs (Vibe Coding).

Investissement

- **Valeur totale de la formation** : 25 475 €.
- **Votre avantage** : un seul paiement de 1 995 €.

Offre de lancement exclusive, code « IA » : -50 % (997,50 € au lieu de 1 995 €), limitée aux 10 premiers inscrits.



[Cliquez ici pour accéder à la page d'inscription](#)

Contacts et rendez-vous offert

Vous avez parcouru ce guide. Maintenant, prenons 15 minutes ensemble pour transformer cette lecture en mise en mouvement concrète.

Rendez-vous de conseil offert : 15 minutes

👉 Profitez d'un moment constructif, créatif et fructueux . Un [rendez-vous de conseil offert de 15 minutes](#), l'occasion pour étudier ensemble vos os besoins de formation en IA

✅ [Vous voulez en profiter ?](#) : 🚀 [cliquez-ici](#)

FORMATION IA 26


Un rendez-vous de conseil : offert

📅 🧡 Profitez d'un moment constructif, créatif et fructueux . Un [rendez-vous de conseil offert de 15 minutes](#), l'occasion pour étudier ensemble vos besoins de formation en IA

✅ [Vous voulez en profiter ?](#)

🚀 [Cliquez sur ce lien](#)





112

Matthieu Jardin



Matthieu Jardin est AI Business Developer, fondateur d'Impact Croissance et de Marketing AI. En quatre ans, il a formé plus de 1000 entrepreneurs et professionnels en IA, sensibilisé plus de 50 000 entrepreneurs, et reçu plus de 416 recommandations sur LinkedIn. Il enseigne en école supérieure et conseille les dirigeants. Sa posture est stable : transmettre d'abord, vendre ensuite ; livrer un système plutôt qu'un savoir ; rester proche du concret plutôt que du jargon.

Mes coordonnées

Email : contact@matthieujardin-formation.fr

Tel. int' : +33 6 29 19 92 87

Tel. : 06 29 19 92 87



[LinkedIn](#)



[Whatsapp](#)



Merci d'avoir lu ce guide.

À très vite, de l'autre côté du passage à l'action.